

Revue de la phase 1 :

Agent IA de Veille Automatisée des AMI/AO

1. Introduction de la première phase

La première phase du projet consiste à mettre en place un système de veille automatisée destiné à collecter des opportunités pertinentes pour le CERT à partir de sources variées (ministères, organisations internationales, opérateurs télécom et régulateurs).

Cette étape inclut la cartographie des portails sources, l'analyse de leur structure et la définition d'une stratégie de collecte et exploitation adaptée.

2. Étude et choix des outils

Afin d'assurer une collecte efficace, plusieurs outils ont été étudiés et sélectionnés.


Les outils :

- **Python** pour sa richesse en bibliothèques dédiées au scraping.
- La Bibliothèque **BeautifulSoup** permettent l'extraction de données HTML statiques.
- La Bibliothèque **Playwright** est utilisé pour les contenus dynamiques (React/Angular).
- La bibliothèque **Feedparser** est utilisée pour la gestion des flux RSS et l'extraction des données.
- **SQLite** pour la base de données et le stockage des données collectées.
- **FastAPI** pour l'exploitation des données collectées.

3. Conception

3.1 MCD :


Une conception préliminaire du modèle conceptuel de données (MCD) permettant de représenter les principales entités du système ainsi que leurs relations.



4. Pipeline d'extraction et d'exploitation

Le système repose sur un pipeline structuré en étapes :

- **Collecte** des données depuis les différentes sources (scrapers/monitors),
- **Nettoyage** et **transformation** des données.
- **Stockage** en base de données.
- **Exploitation** des données.



5. Conclusion

Cette première phase a permis de définir les bases du système de veille automatisée du CERT à travers l'identification des sources prioritaires, l'étude des différentes structures de données et le choix des outils adaptés. La mise en place du pipeline d'extraction et d'exploitation.

La phase suivante consistera à constituer un corpus d'AMI/AO collectés (PDF/HTML) avec annotation des champs clés, puis à développer un module d'extraction basé sur des techniques de NLP permettant d'identifier automatiquement les informations importantes (objet, organisme, dates, budget, critères, lots, documents requis). Elle inclura également la gestion du traitement multilingue (FR/EN/AR), la validation des performances sur le corpus annoté, ainsi que l'extension du système de collecte aux sources restantes.